

# 「2025 CNU Project Fair 창의작품경진대회」 보고서

## [참가부문 : □아이디어 ■학술 □개발과제 ]

작 품 명		해상교통 빅데이터 분석 및 딥러닝 기반 선박 이동 예측 모델 개발							
팀 명		푸른 향로							
팀 원	원소속학과	학번	학년	이름	연락처	이메일	재학 여부(V) (재학생만 상금 수상 가능)		
	수학과	202000826	4	김연범	010-3367-0265	kyb8732@naver.com	재학		
	산림환경자원학과	202102925	4	이한을	010-3012-8621	haneul217@naver.com	재학		
	컴퓨터공학과	201802124	4	이동원	010-6383-9380	woni8062@naver.com	수료		
지도교수		김경섭							
산학멘토		회사명	삼성중공업	성함	이은규	직위	프로	연락처	010-5557-1126
수행기간		2025.03. ~ 2025.11.							
산학협력 진행내용		<ul style="list-style-type: none"><li>■ 관련 업무에 종사 중인 멘토에게 인터뷰를 통해 AIS 데이터의 특성과 산업 현장의 요구를 조사 및 반영하였다.</li><li>■ 멘토와의 인터뷰를 통해 AIS 데이터의 실시간성, 센서 오차 가능성, 산업 내 항로 예측 기술의 필요성 등 다양한 인사이트를 확보하였고, 이를 모델 설계 및 데이터 처리 과정에 적극 반영하였다.</li></ul>							
개요	추진 배경	<p>전 세계 해상 물류의 급증과 함께 선박 이동 경로를 정밀하게 예측하는 기술의 중요성이 더욱 부각되고 있으며, 해상교통의 디지털 전환이 가속화됨에 따라 실시간 항로 예측 시스템에 대한 수요도 증가하고 있다.</p> <p>이에 본 프로젝트는 어텐션 메커니즘 기반의 딥러닝 모델을 적용하여, 선박의 현재 항해 상태와 목적지 정보를 바탕으로 향후 이동 경로를 실시간으로 예측하는 시스템을 구축함으로써, 이러한 기술적·산업적 요구에 효과적으로 대응하는 것을 목표로 한다.</p>							
	목표 및 내용	<p>본 프로젝트의 주요 목표는 AIS 데이터를 기반으로 선박의 이동 경로를 예측할 수 있는 딥러닝 모델을 개발하는 것이다. 특히, 어텐션 기반의 딥러닝 모델을 활용해 목적지를 입력으로 받았을 때, 해당 선박이 항할 예상 경로를 시계열적으로 예측한다. 주요 내용은 다음과 같다.</p> <p>1. AIS 데이터 전처리 및 분석</p>							

		<ol style="list-style-type: none"> <li>1) 위치, 속력(SOG), 방향(COG) 정보를 포함한 대규모 AIS 데이터 정제</li> <li>2) 출발지-목적지 기준의 데이터 그룹화 및 시계열 재구성</li> <li>2. 어텐션 기반 예측 모델 개발               <ol style="list-style-type: none"> <li>1) Transformer의 Encoder 구조를 활용한 시계열 경로 예측 모델 설계</li> <li>2) 과거 항해 이력과 목적지 정보를 기반으로 미래 위치, 속력, 방향 예측</li> </ol> </li> <li>3. 예측 결과 시각화 및 시스템 구현               <ol style="list-style-type: none"> <li>1) 예측 경로와 실제 항로 비교, ETA 시각적 제공</li> <li>2) 예측 경로와 ETA 등을 실시간으로 제공하는 GUI 구현</li> </ol> </li> </ol>
	기대 효과	<p>본 프로젝트를 통해 개발되는 선박 이동 경로 예측 모델은 다음과 같은 효과를 기대할 수 있다.</p> <ol style="list-style-type: none"> <li>1. 해상 물류 운영 효율 향상: 선박의 이동 경로와 도착 시간을 사전에 예측함으로써 항만 운영 및 물류 일정 계획의 정밀도를 높이고, 대기 시간 및 연료 낭비를 최소화할 수 있다.</li> <li>2. 항로 안정성 강화: 예상 경로를 기준으로 교통 혼잡 구간이나 비정상 항로 이탈 등을 사전에 탐지하여, 해양 사고 예방에 기여할 수 있다.</li> <li>3. 자율 운항 및 스마트 해양교통 기술 개발 기반 확보: 본 연구는 향후 자율 운항 선박(MASS) 및 스마트 항만 시스템의 핵심 기술 중 하나로 활용될 수 있는 기반 모델로서 기능할 수 있다.</li> </ol>
세부내용		<p>본 프로젝트는 AIS 데이터를 기반으로 어텐션 중심의 딥러닝 모델을 활용하여 선박의 이동 경로를 예측하는 시스템을 개발하는 것으로, 다음과 같은 세부 절차를 통해 추진된다.</p> <ol style="list-style-type: none"> <li>1. AIS 데이터 수집 및 구성               <ol style="list-style-type: none"> <li>1) 데이터 구성: MMSI, 일시, 위도, 경도, SOG, COG, 선수방향(Heading)</li> <li>2) 전처리 절차:                   <ol style="list-style-type: none"> <li>(1) 30초 간격 시계열 리샘플링: mean-interpolation 활용</li> <li>(2) 이상치 제거: SOG, COG, 위도, 경도별 이상치 제거</li> <li>(3) 출발지-목적지 쌍 기반 그룹화                       <ol style="list-style-type: none"> <li>① 출발 및 목적지 기반으로 동일 항로 그룹 생성</li> <li>② 각 MMSI에 대해 동일 OD 쌍이 반복된 경로를 추출해 모델 학습용 시계열 데이터 구성</li> </ol> </li> </ol> </li> </ol> </li> </ol>

## 2. 입력/출력 구조 정의 및 학습 데이터 구성

### 1) 입력값:

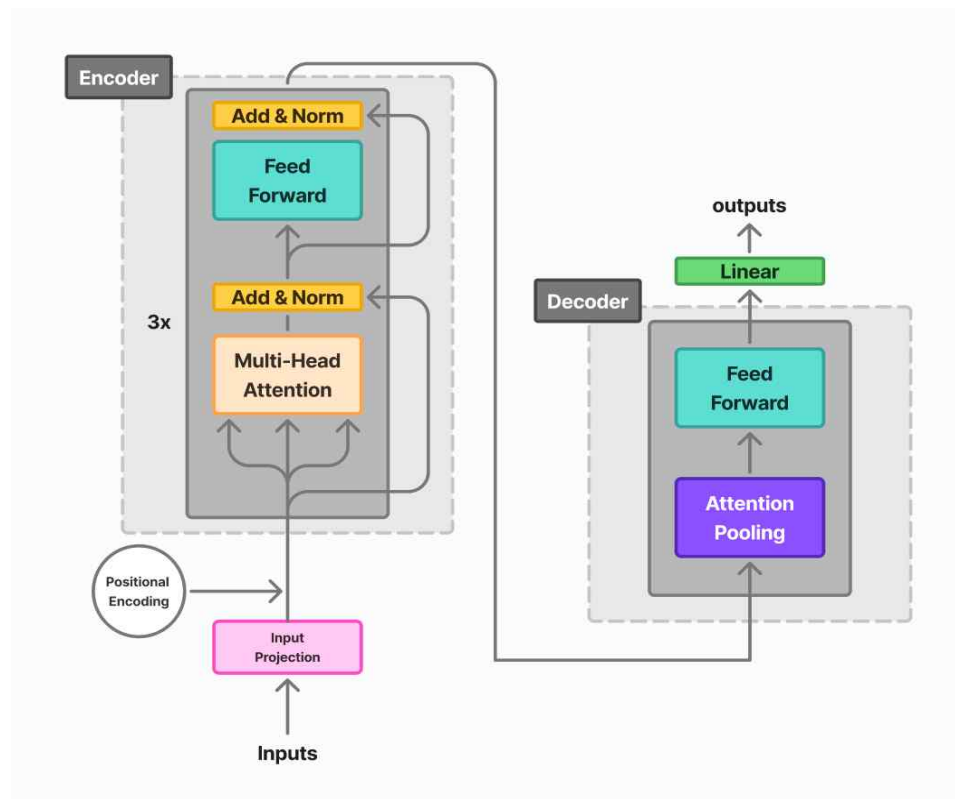
(1) 과거 20분 간격의 데이터(30초 단위, 총 40개), 각 시간에 대해 다음을 포함:

- ① 위도(latitude), 경도(longitude), SOG, COG -> 4차원
- ② 목적지와 현재 위치 간 유클리디안 거리 -> 1차원

### 2) 출력값:

(1) 미래 30초 뒤 시점의 위도, 경도 SOG, COG 예측 -> 4차원 단일 벡터

## 3. 모델 아키텍처 설계



### 1) 인코더 구조(Transformer 기반):

- (1) Input Projection을 통해 입력 시계열 데이터를 Transformer가 처리할 수 있는 고정 차원의 벡터로 임베딩
- (2) 포지셔널 인코딩(Positional Encoding)을 적용하여 시계열 순서 정보 반영
- (3) 멀티 헤드 어텐션(Multi-head Self-Attention)을 적용해 시점 간 상호관계 학습
- (4) Residual Connection과 Layer Normalization을 적용해 학습 안정성 및 정보 손실 방지

## 2) 디코더 구조(MLP 기반)

- (1) 어텐션 풀링(Attention Pooling)을 적용해 전체 시퀀스의 핵심 정보를 요약하여 고정 길이 벡터 추출
  - (2) Fully Connected Layer를 통해 위도, 경도, SOG, COG를 예측
  - (3) 비선형 활성화 함수로 GELU(Gaussian Error Liner Unit)를 사용해 모델의 표현력 향상
- 3) 모델 목적: 시간순 위치 데이터의 흐름과 목적지 정보를 함께 고려하여 다음 시점의 이동 상태를 정확히 예측

## 4. Loss Function 및 학습 전략

### 1) 복합 Loss 구성:

```
# 위치 오차 (위경도 기준)
loc_loss = F.mse_loss(pred_lat, true_lat) + F.mse_loss(pred_lon, true_lon)

# SOG, COG 오차
motion_loss = (
    (1-cog_weight) * F.mse_loss(pred_sog, true_sog) +
    cog_weight * F.mse_loss(pred_cog, true_cog)

# 최종 Loss: 위치 오차 + SOG, COG 오차
total_loss = (
    self.weight_main * loc_loss +
    (1 - self.weight_main) * motion_loss
)
```

- (1) loc\_loss: 위도, 경도에 대한 MSE
- (2) motion\_loss: SOG, COG에 대한 MSE
- (3) weight\_main, cog\_weight 하이퍼 파라미터를 통해 가중치 조절

### 2) 훈련 방식:

- (1) 단일 스텝 예측 학습: 20분 입력 -> 30초 예측
- (2) 배치 단위의 시퀀스 훈련, weight decay를 적용하는 AdamW 옵티마이저를 사용해 더 나은 일반화 성능 확보
- (3) Cosine-Annealing 스케줄링을 통해 학습률을 코사인 곡선 형태로 조절하여, 빠른 초기 학습과 안정적인 후반 수렴 동시 달성
- (4) Gradient Norm Clipping 기법을 적용해 Gradient Exploding 방지
- (5) Noise Injection 기법을 활용해 차후 Auto-regressive Inference 과정에서의 강건성 확보

## 5. 자가회귀 기반 경로 예측 및 생성

### 1) Auto-regressive Inference:

- (1) 20분 입력 -> 30초 출력 -> 이 출력을 다음 입력의 가장 최근 시점으로 추가
- (2) 반복적으로 예측을 수행하여 최종 목적지 도달까지 전체 경로를 생성
- (3) 예측 시마다 목적지 정보는 고정 입력으로 유지
- (4) Monte-Carlo Dropout(MC Dropout) 기법을 활용하여, 매 step 마다 dropout을 적용, 이들의 평균을 사용함으로써 error accumulation 현상을 완화

### 2) 예측 종료 조건:

- (1) 목적지 좌표와의 거리가 일정 기준 이하일 경우 종료
- (2) 또는 최대 반복 횟수 도달 시 종료


## 6. 지도 기반 예측 경로 시각화

### 1) 시각화 도구:

- (1) folium 라이브러리 기반 지도에 예측 경로(자가 회귀 결과) 시각화
- (2) 실제 경로와의 비교를 통해 오차 확인 및 성능 평가 가능

### 1. 모델 학습 과정 시각화:

모델 학습은 총 20 Epoch 동안 진행되었으며, 아래 그래프는 학습 중 Train loss와 Validation loss의 수렴 양상을 보여준다.

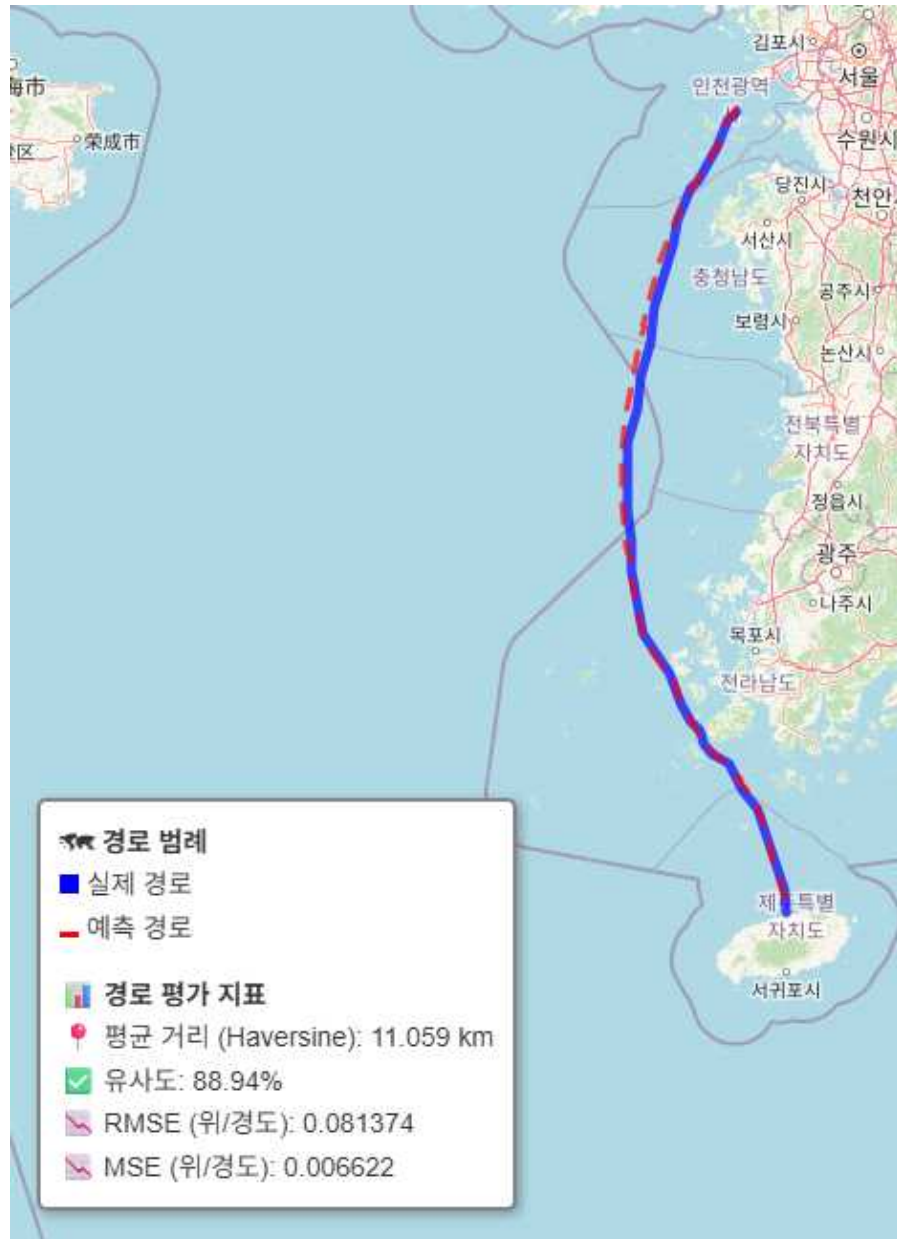


개발결과

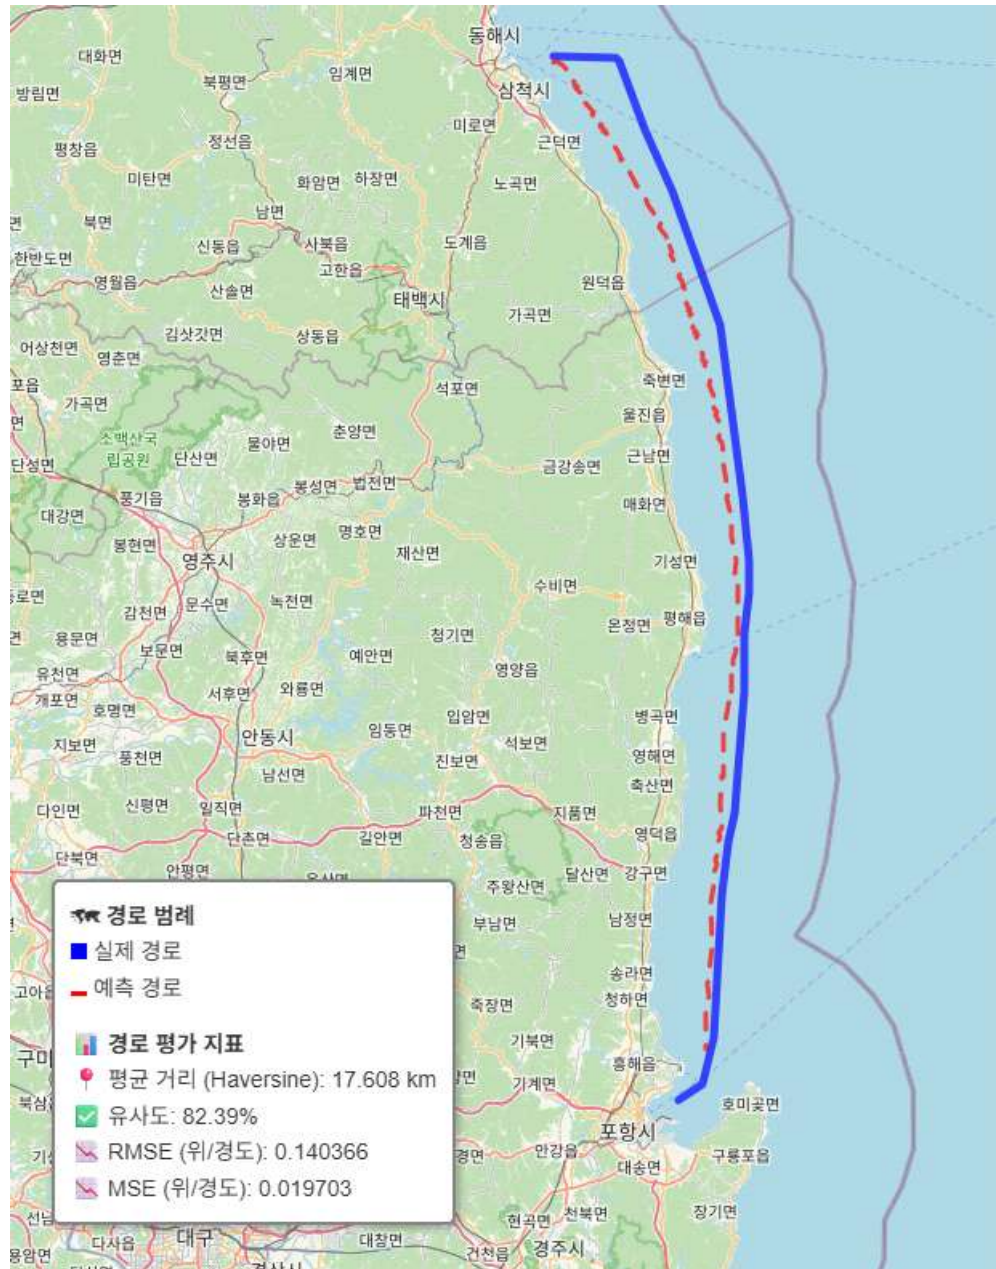
## 2. 예측 결과 vs 실제 경로 시각화:

아래 지도는 각 항로 사례에 대한 예측 경로와 실제 경로를 비교한 결과이다. 예측 경로는 목적지까지 안정적으로 수렴하고 있다는 사실을 보여준다.

### 1) 인천항 -> 제주항

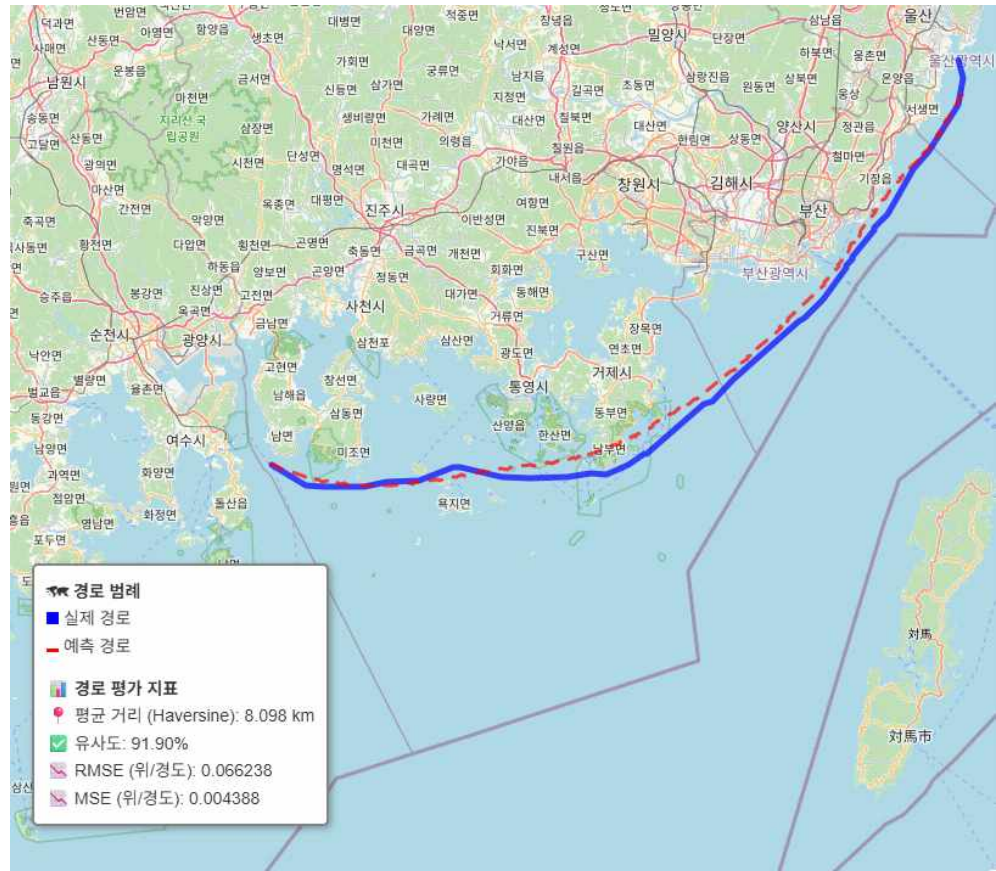


## 2) 동해항 -> 포항항





### 3) 여수항 -> 울산항



### 3. 경로 평가 지표 요약

예측 경로의 정량적 평가 지표는 다음과 같은 기준으로 설정했다. (단위: 30초)

- 1) 평균 거리(Haversine): 실제 경로와 예측 경로 간 평균 Haversine 거리 오차.
- 2) 유사도: 실제 경로와 예측 경로 간 경로 유사도, 평균 거리 지표를 기준으로 측정.
- 3) RMSE: 실제 경로와 예측 경로 간 위도, 경도 RMSE
- 4) MSE: 실제 경로와 예측 경로 간 위도, 경도 MSE